

Αναγνώριση Προτύπων και Μηχανική Μάθηση

1η Εργασία



ΑΜ : 161173

Ονοματεπώνυμο : Βεσέλ Νταλίπαϊ

Εισαγωγή

Στόχος της εργασίας είναι η ανάπτυξη και αξιολόγηση μοντέλων επιβλεπόμενης μάθησης - ταξινόμησης για την πρόβλεψη χρεωκοπίας ελληνικών εταιρειών, με βάση οικονομικών δεικτών.

Τα δεδομένα δίνονται σε αρχείο Excel και περιλαμβάνουν 11 χαρακτηριστικά (στήλες A–K) που αντιστοιχούν σε δείκτες απόδοσης και δραστηριότητας. Η μεταβλητή στόχος είναι η στήλη Status(ΕΝΔΕΙΞΗ ΑΣΥΝΕΠΕΙΑΣ (=2) (n+1) στο excell), όπου 1=Healthy και 2=Bankrupt. Η στήλη ΕΤΟΣ δεν χρησιμοποιείται οπότε την αγνοούμε.

Το μοντέλο πρέπει να εντοπίζει τις χρεωκοπημένες με sensitivity $\geq 62\%$ και τις υγιείς με specificity $\geq 70\%$.

Μέθοδοι

Στο πρόγραμμα αρχικά γίνεται εισαγωγή των δεδομένων από αρχείο Excel με τη χρήση της read_excel της βιβλιοθήκης pandas και αφαιρείται η στήλη του έτους μέσω της μεθόδου drop, ενώ στη συνέχεια εμφανίζονται οι πρώτες γραμμές με head για έλεγχο.

Έπειτα επιλέγονται οι 11 πρώτες στήλες ως χαρακτηριστικά με iloc, ενώ ορίζεται η τυποποίηση χαρακτηριστικών με StandardScaler, που μετά τον διαχωρισμό εφαρμόζεται με fit_transform στο training set και με transform στο test set.

Η στήλη στόχος (Status) επιλέγεται επίσης με iloc και γίνεται δυαδική κωδικοποίηση με np.where ώστε να προκύψουν οι κλάσεις Healthy/Bankrupt.

Ακολουθεί διαχωρισμός σε training και test set με τη μέθοδο `train_test_split` και χρήση `stratify` ώστε να διατηρηθεί η αναλογία των κλάσεων.

Στη συνέχεια υπολογίζεται η κατανομή των κλάσεων στο training set με `np.sum` και, αν υπάρχει μεγάλη ανισορροπία, γίνεται `downsampling` στους Healthy με `np.where` για εύρεση θέσεων και `rng.choice` για τυχαία επιλογή, ενώ τα τελικά δείγματα ενώνονται με `np.concatenate` και ανακατεύονται με `rng.shuffle`.


Μετά ορίζονται οι ταξινομητές (LDA, Logistic Regression, KNN, GaussianNB, SVM RBF, MLP) και για κάθε μοντέλο γίνεται εκπαίδευση με `fit` και παραγωγή προβλέψεων με `predict` τόσο στο train όσο και στο test.

Για την αξιολόγηση υπολογίζονται `confusion matrices` ανά κλάση με `multilabel_confusion_matrix`, εξάγονται τα TP/TN/FP/FN και στη συνέχεια υπολογίζονται οι βασικές μετρικές με `precision_score`, `recall_score`, `f1_score` και `accuracy_score`, μαζί με `Sensitivity` και `Specificity` από τους αντίστοιχους τύπους.

Τέλος τα αποτελέσματα συγκεντρώνονται σε `DataFrame` με `pd.DataFrame`, δημιουργείται ο φάκελος εξόδου με `os.makedirs` αν χρειάζεται, και αποθηκεύονται σε Excel με τη μέθοδο `to_excel`.

Αποτέλεσμα

	Classifier Name	Train/Test Set	Samples Count	TP	TN	FP	FN	Precision	Recall	F1 Score	Accuracy
0	LDA	Train	744	83	523	35	103	0.7694	0.6918	0.7147	0.8145
1	LDA	Test	2679	29	2400	217	33	0.5522	0.6924	0.5694	0.9067
2	Logistic Regression	Train	744	85	522	36	101	0.7702	0.6962	0.7189	0.8159
3	Logistic Regression	Test	2679	29	2375	242	33	0.5467	0.6876	0.5597	0.8973
4	KNN (k=5)	Train	744	123	516	42	63	0.8183	0.7930	0.8043	0.8589
5	KNN (k=5)	Test	2679	35	2301	316	27	0.5441	0.7219	0.5501	0.8720
6	KNN (k=7)	Train	744	108	511	47	78	0.7822	0.7482	0.7622	0.8320
7	KNN (k=7)	Test	2679	36	2320	297	26	0.5485	0.7336	0.5586	0.8794
8	KNN (k=9)	Train	744	105	511	47	81	0.7770	0.7401	0.7550	0.8280
9	KNN (k=9)	Test	2679	36	2337	280	26	0.5515	0.7368	0.5645	0.8858
10	GaussianNB	Train	744	95	496	62	91	0.7250	0.6998	0.7102	0.7944
11	GaussianNB	Test	2679	33	2296	321	29	0.5404	0.7048	0.5439	0.8694
12	SVM (RBF)	Train	744	119	539	19	67	0.8759	0.8029	0.8303	0.8844
13	SVM (RBF)	Test	2679	34	2375	242	28	0.5558	0.7280	0.5737	0.8992
14	MLP (64,32)	Train	744	185	553	5	1	0.9859	0.9928	0.9893	0.9919
15	MLP (64,32)	Test	2679	32	2207	410	30	0.5295	0.6797	0.5182	0.8358



Συμπεράσματα

Στα αποτελέσματα παρατηρείται ότι όλα τα μοντέλα πετυχαίνουν υψηλή Specificity (Healthy), άρα αναγνωρίζουν σωστά τις περισσότερες υγιείς εταιρείες και έχουν λίγα false positives. Αντίθετα, η Sensitivity (Bankrupt) παραμένει χαμηλότερη από το απαιτούμενο όριο, κάτι που σημαίνει ότι αρκετές πτωχευμένες

εταιρείες ταξινομούνται λανθασμένα ως υγιείς (false negatives). Αυτό δείχνει και το βασικό πρόβλημα της ανισορροπίας κλάσεων: η Accuracy μπορεί να είναι σχετικά υψηλή, αλλά δεν αποτυπώνει καλά την ικανότητα ανίχνευσης της κλάσης Bankrupt, που είναι και η πιο κρίσιμη. Συνεπώς, με τις default προβλέψεις των μοντέλων και το συγκεκριμένο balancing, ικανοποιείται συνήθως ο περιορισμός της Specificity, αλλά όχι αυτός της Sensitivity.